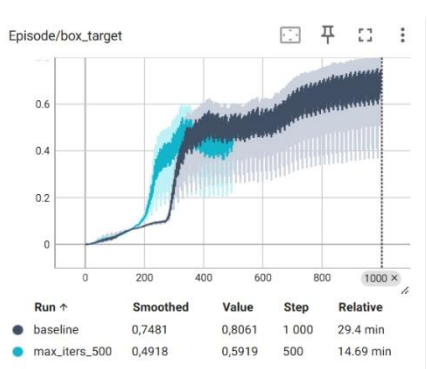
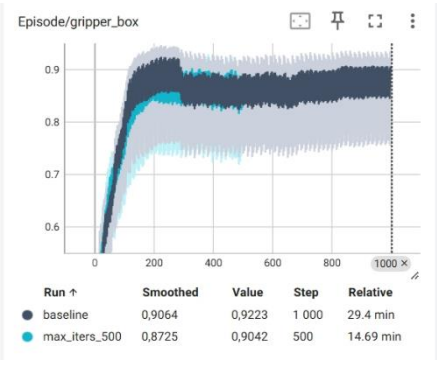
Таблица экспериментов

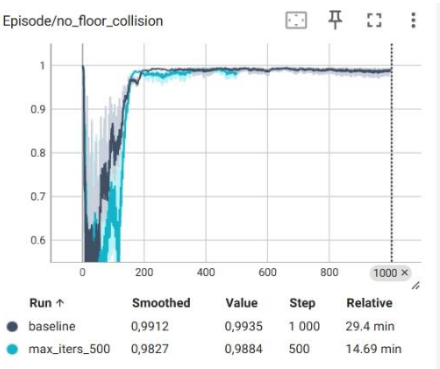
Эксперимент	Изменения в коде	Команда запуска	mean-reward	SR (k/10)	Время	Поведение
baseline	—	python3 train.py --exp_name baseline	1341.39	9/10	1872 с (31.2 мин)	Робот дотягивается до куба, подхватывает его и стабильно доносит до целевой точки. В 9 из 10 эпизодах куб оказался в пределах 5 см от цели.
max_iters_500	python EXP_NAME = "max_iters_500 " MAX_ITERS = 500	—	1143.61	8/10	892 с (14.9 мин)	Стал промахиваться чаще, не во всех эпизодах доносит куб до цели.
box_target_strong_40.0	env_cfg.reward_config.scales.box_target = 40.0	python3 train.py --exp_name box_target_strong	4614.64	10/10	1782 с (29.7 мин)	Алгоритм нашёл стратегию, при которой стремится уменьшить расстояние куба до цели. Робот идеально доносит куб в 10/10 эпизодах, так как усиленная компонента совпадает с реальной задачей.
qpos_strong	env_cfg.reward_config.scales.robot_target_qpos = 30.0	python3 train.py --exp_name qpos_strong	4523.24	0/10	1419 с (23.6 мин)	Робот стоит неподвижно в стартовой позе, не делает попыток подойти к кубу. Высокий mean_reward достигнут за счет максимизации вспомогательной награды за неподвижность.
box_target_strong_4.0 (собственный эксперимент)	env_cfg.reward_config.scales.box_target = 4.0	python3 train.py --exp_name box_target_strong	969.53	10/10	1847 с (30.8 мин)	Робот в 10/10 эпизодах доносит куб до цели. Справился даже лучше, чем baseline

Измение max_iters (уменьшаем число итераций вдвое относительно baseline)

EXP_NAME = "max_iters_500"; MAX_ITERS = 500







На графиках TensorBoard видно, что при max_iters_500 обучение обрывается на 500-й итерации. Компонент награды box_target (приближение куба к цели) не успевает достичь уровня baseline. Захват куба (gripper_box) в обоих случаях происходит хорошо. Это подтверждает, что из-за сокращения времени обучения модель не успевает выйти на плато по основным метрикам, что привело к падению SR с 9/10 до 8/10.

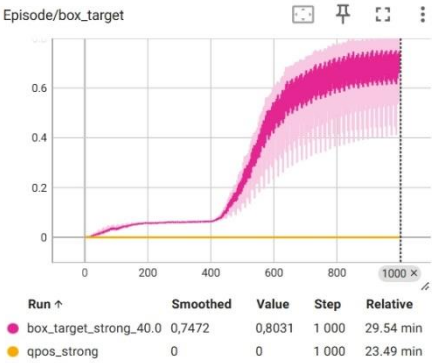
Усиление box_target

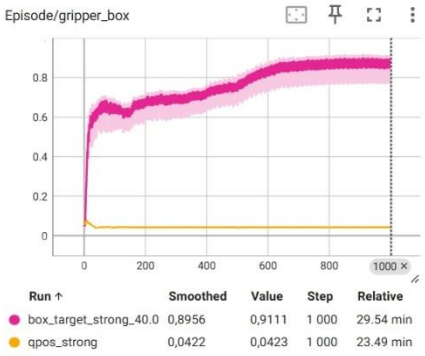
В данном эксперименте вес основной компоненты награды box_target был увеличен в 5 раз. Это привело к значительному росту метрики оптимизации: mean_reward достиг 4614.64, что в несколько раз выше baseline. Алгоритм успешно максимизировал заданную функцию. Поскольку компонента box_target напрямую описывает нашу реальную задачу, усиление этой награды заставило политику активно и точно доставлять куб. На инференсе это подтвердилось. Робот стабильно хватает куб и доносит его до целевой точки в 10/10 эпизодах.

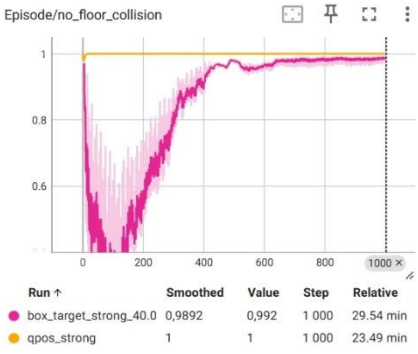
Этот эксперимент показывает: что если усилить основную компоненту награды, то mean_reward и SR растут согласованно. Алгоритм максимизирует число, и это число идеально отражает решение задачи.

Усиление вспомогательной компоненты robot_target_qpos

При увеличении веса вспомогательной компоненты robot_target_qpos до 30.0 алгоритм нашел «идеальную» стратегию стоять неподвижно в стартовой позе. Поскольку вес этой компоненты стал доминирующим, робот получал огромную награду просто за бездействие. SR 0/10.







Графики наглядно демонстрируют разницу между типами наград. Усиление основной компоненты (box_target, отвечающей за приближение куба к цели) заставляет робота решать задачу, даже если процесс обучения выглядит нестабильным. В то же время усиление вспомогательной компоненты (robot_target_qpos, отвечающей за стартовую позу) полностью "ломает" политику: алгоритм находит самый простой путь для получения очков, просто стоя на месте, игнорируя куб.

Это доказывает, что mean_reward — это лишь число, которое максимизирует алгоритм. Только правильная настройка весов награды и независимая проверка (SR) позволяют получить действительно полезную политику.

Эксперимент: box_target = 4.0 (ослабление основной награды)

Гипотеза: если уменьшить вес box_target с 8.0 до 4.0, то mean_reward и SR снизятся по сравнению с baseline, так как у робота пропадет сильный стимул доставлять куб к цели, и он будет больше фокусироваться на других компонентах награды.

Параметр	Изменение	Ожидание по mean_reward	Ожидание по SR	Обоснование
env_cfg.reward_config.scales.box_target	Уменьшить в 2 раза (с 8.0 до 4.0)	Снизится по сравнению с baseline. Т.к. мы уменьшили вес основной компоненты, общая сумма награды, которую собирает робот, станет меньше.	Снизится. Робот будет хорошо подходить к кубу (gripper_box), но у него пропадет стимул тащить его до конца к цели, так как за это теперь дают мало очков. SR 6/10.	box_target это основная награда, которая напрямую соответствует задаче (SR). Уменьшая ее в 2 раза, мы делаем задачу менее приоритетной для алгоритма по сравнению с дефолтными настройками.

Результат: гипотеза подтвердилась частично. Ожидалось, что SR снизится, но он, наоборот увеличился с 9/10 до 10/10. Возможно box_target = 8.0 был даже избыточным. Снижение веса box_target до 4.0 сделало обучение более сбалансированным: робот перестал делать лишние резкие движения ради огромной награды, а сосредоточился на аккуратном выполнении задачи. mean_reward упал по сравнению с baseline. Несмотря на то что мы уменьшили вес основной награды, компонента gripper_box осталась прежней, и алгоритм всё равно выучил базовую стратегию захвата. Уменьшение веса основной компоненты награды не сломало задачу (в отличие от эксперимента с гигантским весом), а лишь снизило абсолютное значение mean_reward, при этом качество реального выполнения задачи осталось на высшем уровне.

